

Trabalho de Algoritmo Genético e Redes Neurais

Prof.: Laercio Brito

Seleção de Atributos em Base de Dados de Câncer do Colo do Útero Utilizando Algoritmos Genéticos e Redes Neurais

1. Objetivo

O objetivo deste trabalho é desenvolver um sistema de seleção automática de atributos para uma base de dados relacionada ao câncer do colo do útero, utilizando Algoritmos Genéticos (AG) como mecanismo de busca e Redes Neurais Artificiais (RNA) treinadas pelo algoritmo Backpropagation como função de avaliação das soluções geradas.

O foco do trabalho é investigar o impacto da redução de dimensionalidade sobre o desempenho de classificação da rede neural, identificando subconjuntos de atributos que maximizem a capacidade preditiva do modelo.

2. Base de Dados

Será utilizada uma base de dados relacionada ao câncer do colo do útero. A base de dados se encontra na plataforma Teams em uma versão completa e outra pré reduzida.

3. PRÉ-PROCESSAMENTO DOS DADOS

Antes da execução do algoritmo genético deverão ser realizadas as seguintes etapas:

1. Tratamento de valores ausentes;
2. Remoção de registros inconsistentes;
3. Conversão de atributos categóricos para formato numérico;
4. Análise exploratória dos dados;
5. Aplicação da normalização linear Min-Max.

A normalização deverá ser realizada conforme:

$$x' = (x - x_{\min}) / (x_{\max} - x_{\min})$$

onde:

- x = valor original;
- $x_{\min}$ = menor valor do atributo;
- $x_{\max}$ = maior valor do atributo.

Após a normalização, todos os atributos deverão estar no intervalo $[0,1]$.

4. REPRESENTAÇÃO DO CROMOSSOMO

Cada cromossomo representará um subconjunto de atributos da base de dados.

Será utilizada codificação binária, onde:

- Gene = 1 $\rightarrow$ atributo selecionado;
- Gene = 0 $\rightarrow$ atributo não selecionado.

Exemplo:

A1	A2	A3	A4	A5	A6
1	0	1	1	0	1

Nesse exemplo, apenas os atributos A1, A3, A4 e A6 serão utilizados pela rede neural.

O comprimento do cromossomo será igual ao número total de atributos da base de dados.

5. CONFIGURAÇÃO DO ALGORITMO GENÉTICO

- Tamanho da população: 150 cromossomos.
- Será utilizado o operador de Crossover Uniforme.
- Probabilidade de crossover (P_c): 0,85.
- Probabilidade de mutação: $P_m = 1 / L$, onde L representa o comprimento do cromossomo.
- Elistismo: Os 10 melhores indivíduos deverão ser preservados integralmente a cada geração.
- Será utilizada a abordagem Steady-State Genetic Algorithm. Gap = 2
- Critérios de parada:

- 200 gerações completas ou;
- 20 gerações consecutivas sem melhoria da melhor solução.

6. FUNÇÃO DE APTIDÃO

A aptidão de cada cromossomo será determinada pelo desempenho de uma Rede Neural Artificial treinada utilizando exclusivamente os atributos selecionados pelo cromossomo.

A medida principal de desempenho será o F1-Score.

A função de aptidão será definida por:

$$\text{Fitness} = 0,9 \times \text{F1-Score} + 0,1 \times (1 - N_s/N_t)$$

onde:

- N_s = número de atributos selecionados;
- N_t = número total de atributos.

Dessa forma, busca-se simultaneamente:

- Maximizar a capacidade preditiva;
- Minimizar o número de atributos utilizados.

Após o cálculo da aptidão, deverá ser aplicada a normalização linear dos valores de fitness para escalonamento da população.

7. CONFIGURAÇÃO DA REDE NEURAL

A Rede Neural será utilizada como avaliadora dos indivíduos gerados pelo algoritmo genético.

7.1 Arquitetura

Camada de Entrada

Número de neurônios igual ao número de atributos selecionados.

Primeira Camada Oculta

- 32 neurônios;
- Função de ativação ReLU.

Segunda Camada Oculta

- 16 neurônios;
- Função de ativação **ReLU**.

Camada de Saída

- **Quantidade de neurônios igual ao número de classes da base de dados**
- Função de ativação: **Softmax**

A saída representará a distribuição de probabilidade entre as classes.

Obs.:

ReLU (Rectified Linear Unit) é uma função que zera valores negativos e mantém valores positivos

$$f(x)=\max(0,x)$$

A **Softmax** transforma um vetor de valores em probabilidades que somam 1

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}}$$

Se a rede gera:

$$z=[2.0, 1.0, 0.1]$$

Depois do Softmax:

- Classe 1: 0.66
- Classe 2: 0.24
- Classe 3: 0.10

7.2 Treinamento

Algoritmo:

- Backpropagation.

Otimizador:

- Adam.

O **Adam** é um algoritmo de otimização usado para treinar redes neurais. Ele é, basicamente, uma versão ñinteligente do **gradiente descendente**, com melhorias para tornar o aprendizado mais rápido e estável.

Adam (Adaptive Moment Estimation) é um otimizador que combina duas ideias:

- **Momento (Momentum)** ÿ lembra a direção dos gradientes anteriores
- **Taxa de aprendizado adaptativa** ÿ ajusta o passo automaticamente para cada peso

Taxa de aprendizado:

- 0,001.
- Melhor configuração da rede neural será a que der menor erro no conjunto de validação

8. PROCEDIMENTO EXPERIMENTAL

Os dados deverão ser divididos em:

- 70% para treinamento;
- 15% para validação;
- 15% para teste.

Para cada cromossomo avaliado:

1. Selecionar os atributos indicados pelos genes ativos;
2. Construir a rede neural correspondente;
3. Treinar a rede neural;
4. Calcular o F1-Score;
5. Calcular o fitness;
6. Atualizar a população do algoritmo genético.

Ao final do processo deverão ser apresentados:

- Melhor cromossomo encontrado;
- Número de atributos selecionados;

- Curva de convergência do algoritmo genético; (média dos melhores em 20 experimentos completos)

Observações:

Cada grupo deverá entregar:

1. Código-fonte completo;
2. Relatório técnico;
3. Descrição dos experimentos realizados;
4. Tabela contendo os parâmetros utilizados;
5. Gráficos de evolução do algoritmo genético;
6. Análise crítica dos resultados.